基於前面多次搜索已經取得的詳細論文內容，我直接進行深度梳理。

語音品質評估的語義 ISA 形式化四部曲

全景對照表：四篇論文如何逐步逼近語義 ISA

我先用一張完整的對照表，然後逐一展開每個演化步驟中「發生了什麼」和「為什麼這一步是必要的」。

維度	ALLD (ICLR 2025)	QualiSpeech (ACL 2025)	SQ-LLM (arXiv 2025.10)	Calibration-Reasoning (arXiv 2026.03)
核心問題	Audio LLM 能不能感知品質？	能不能用自然語言**推理**品質？	能不能跨任務、跨語言地**通用評估**？	能不能用 RL **保證**描述的精確性？
操作定義的精確度	模糊（「描述品質」）	結構化（11 維度 + 時間定位）	操作家族（4 種任務類型）	帶可靠性約束的操作
品質維度	5 個（MOS, noi, dis, col, loud）	11 個（+speed, effort, naturalness, continuity, gender, 描述+推理）	多語言多任務	同 QualiSpeech，但加入時間定位精度
輸出格式	自然語言描述 + MOS 數字	結構化描述（維度分數 + 維度描述 + 因果推理 + 整體評論）	描述 / 比較 / 建議 / 檢測	結構化描述 + artifact 時間區間
資料來源	LLM 從 meta-info 生成	人工標註 + LLM 生成 + 人工修正（三步流程）	30K 語音、128K 標註、4 語言	同 QualiSpeech corpus
優化方法	DPO token-level distillation	SFT fine-tuning	SFT + 多任務	**GRPO (RL) + 維度特定獎勵**
可靠性度量	MSE, LCC, SRCC, BLEU	PCC per dimension, Correlation score, IoU	LLM score, human correlation	PCC + F1 (artifact 檢測) + IoU (時間定位) + ROUGE-L
失效模式分析	無	發現模型對某些維度完全失效（nan）	發現未 fine-tune 的模型幾乎不可用	發現 SFT 的推理常 ungrounded
ISA 類比	「我們發現這條指令存在」	「我們定義了指令的輸入/輸出格式」	「我們發現這是一個指令家族」	「我們開始定義指令的可靠性保證」

第一步：ALLD——「發現指令存在」

時間：2025 年 1 月（arXiv），2025 年 4 月（ICLR 2025） **團隊**：NVIDIA Research Taiwan + NTU (Chen Chen, Yuchen Hu, Eng Siong Chng 等)

之前的狀態

在 ALLD 之前，語音品質評估的範式是：

— 傳統方法：輸入音頻 → 輸出一個 MOS 數字（1-5 分）。代表性方法如 NISQA、UTMOS。 — 這些方法的「ISA」是一條極簡的指令：`PREDICT_MOS(audio) → float`。輸入是波形，輸出是一個純量。完全在語法空間中。

沒有人問過：「Audio LLM 能不能不只給一個分數，而是用自然語言**描述**品質？」

ALLD 做了什麼

ALLD 引入了第一個自然語言語音品質評估語料庫，從真實人類評分中生成。除了整體 MOS 外，這個語料庫提供跨多個維度的詳細分析，並識別品質退化的原因。

具體的做法是：

資料集建構：從 IU-Bloomington 的 MOS 標註資料中，取出每個語音樣本的多維度評分（MOS, 噪音, 失真, 著色, 響度），然後用 LLM（GPT-4）根據這些 meta-info 生成自然語言描述。

訓練方法：用 DPO（Direct Preference Optimization）的 token-level distillation——讓一個 expert LLM（能看到 meta-info）的輸出作為「偏好回應」，audio LLM（只能看到原始音頻）的輸出作為「非偏好回應」，透過偏好優化讓 audio LLM 學會從原始音頻直接生成類似 expert 的品質描述。

關鍵發現：當手動修改生成的描述（例如把「有顯著背景噪音」改成「沒有任何背景噪音」）時，最終的 MOS 估計值會因為修改而提升——描述和數值預測之間確實存在因果關聯。

用語義 ISA 的語言來說

ALLD 證明了一條新的語義指令是可能的：

```
舊指令：PREDICT_MOS(audio) → float
新指令：DESCRIBE_QUALITY(audio) → text + float
```

但這條新指令的定義還非常模糊： — 輸出的自然語言描述沒有固定格式（可以是任意的句子） — 品質維度被硬編碼為 5 個（由訓練資料決定） — 沒有定義在什麼條件下描述是「正確」的 — 沒有時間定位（不知道問題發生在語音的哪個時間段） — 沒有推理鏈（只描述「是什麼」，不解釋「為什麼」）

ISA 類比：這就像 1950 年代的早期電腦——人們發現「原來可以用電路做加法」，但還沒有定義 ADD 指令的精確語義（操作碼格式、溢位行為、旗標設定等等）。

第二步：QualiSpeech——「定義指令的輸入/輸出格式」

時間：2025 年 3 月（arXiv），2025 年 7 月（ACL 2025 Long Paper） **團隊**：清華大學 Chao Zhang 組 + Yu Tsao (中研院) + Junichi Yamagishi (NII)

為什麼需要這一步

ALLD 的資料集有兩個根本性問題：

問題一：描述是 LLM 從 meta-info 生成的，沒有人類驗證。LLM 可能產生幻覺——說「有噪音」但其實沒有，或者錯誤描述噪音的類型。

問題二：只有 5 個維度，而且沒有「描述」的結構定義。一段品質描述可以寫成「聲音有點吵」也可以寫成「在 0.5-1.2 秒之間有來自空調的穩態噪音，導致 500Hz 以下的頻段被遮蔽」——兩者都算「描述」，但資訊密度天差地別。

QualiSpeech 做了什麼

QualiSpeech 引入了一個全面的低層級語音品質評估資料集，涵蓋 11 個關鍵面向和包含推理與上下文洞察的詳細自然語言評論。

具體的推進：

維度擴展：從 ALLD 的 5 個維度擴展到 11 個——加入了語速（speed）、聽力負擔（listening effort）、自然度（naturalness）、連續性（continuity）、性別辨識（gender）等。每個維度都有**兩種標註**：數值分數（1-5）和自然語言描述。

時間定位：對於噪音、失真、不自然停頓這三種 artifact，標註了**精確的時間區間**——不只是「有失真」，而是「在 1.5s-2.5s 之間有電流感的失真」。

三步標註流程：(1) 人類聽者標註數值分數和基本描述 → (2) GPT 根據 meta-info 生成詳細的自然語言評論（包含推理和因果分析）→ (3) 人類審核和修正 GPT 的輸出。這個三步流程比 ALLD 的純 LLM 生成可靠得多。

推理（Reasoning）：描述不只是列舉各維度的狀態，而是包含因果推理——「**因為**這段語音在 2-3 秒之間有明顯的電流失真，**而且**背景噪音在整段期間持續存在，**所以**整體 MOS 被拉低到 2.5。如果能消除失真問題，MOS 預計可以提升到 3.5。」

Benchmark 建立：QualiSpeech 不只是資料集——它定義了一個 benchmark，包含標準化的評估指標。對每個維度分別計算 PCC（Pearson Correlation Coefficient），對描述文字用 GPT-4o 計算語義相關性分數，對時間定位計算 IoU（Intersection over Union）。

用語義 ISA 的語言來說

QualiSpeech 把 ALLD 的模糊指令精細化為一個有**結構化輸入/輸出規格**的指令：

```
指令：QUALITY_ASSESS(audio) → StructuredReport

StructuredReport = {
  scores: {
    noise: int[1-5],
    distortion: int[1-5],
    naturalness: int[1-5],
    continuity: int[1-5],
    listening_effort: int[1-5],
    speed: int[1-5],
    mos: float[1-5]
  },
  descriptions: {
    noise: {type: str, time_intervals: [(start, end)], severity: str},
    distortion: {type: str, time_intervals: [(start, end)], severity: str},
```

```
    unnatural_pauses: {time_intervals: [(start, end)]},
    overall: str  // 包含因果推理的整體評論
  },
  reasoning: str  // "因為 X 所以 Y" 的推理鏈
}
```

ISA 類比：這就像從「我們知道可以做加法」進化到「ADD 指令的操作碼是 0x01，接受兩個 32-bit 整數操作數，結果存入目標暫存器，溢位時設定 OF 旗標」。輸入/輸出格式被精確定義了。

但仍然缺少：**可靠性保證**。QualiSpeech benchmark 測量了模型的表現，但沒有定義「達到什麼表現才算滿足規格」。它告訴你模型的 PCC 是 0.72，但沒有說 PCC 需要 ≥ 0.80 才算合格。

第三步：SQ-LLM——「發現這是一個指令家族」

時間：2025 年 10 月（arXiv） **團隊**：Nankai University + Microsoft Research

為什麼需要這一步

ALLD 和 QualiSpeech 都只做了一件事：**描述語音品質**。但在真實應用中，「品質評估」不是一個單一操作——它是一個**操作家族**：

— 有時候你需要**單獨評估**一段語音（descriptive assessment） — 有時候你需要**比較**兩段語音哪個更好（pairwise comparison） — 有時候你需要**建議**怎麼改善品質（quality improvement suggestion） — 有時候你需要**檢測**語音是否是深偽造的（deepfake detection）

這四種操作有不同的輸入/輸出格式、不同的可靠性需求、不同的評估指標。把它們混在一個「品質評估」指令裡是不夠的。

SQ-LLM 做了什麼

ALLD、QualiSpeech 和 Wang et al. 顯示，在直接評估中 speech LLM 在語音品質 benchmark 上表現不佳，只有經過任務特定的 fine-tuning 之後才能可靠地產生描述性回饋。

SQ-LLM 的核心貢獻是把「品質評估」拆分為四個獨立的語義操作，並為每個操作建立了獨立的資料集和評估方法：

SpeechEval 資料集：超過 30,000 語音片段、128,000 標註、4 種語言（英語、中文、日語、德語），涵蓋四種評估任務。

四種操作的具體定義：

操作 A：Descriptive Assessment（描述性評估） — 繼承 ALLD/QualiSpeech 的路線，但擴展到多語言 — 輸入：單段語音。輸出：多維度品質描述 + 推理

操作 B：Pairwise Comparison（成對比較） — 輸入：兩段語音。輸出：哪個更好 + 為什麼（自然語言解釋） — 這是 ALLD 的 A/B test 的擴展，但加入了更詳細的比較推理

操作 C：Quality Improvement Suggestion（品質改善建議） — 輸入：一段品質不佳的語音 + 其品質描述。輸出：具體的改善建議 — **這是全新的——之前沒有人做過。** 它開始觸及我們討論的 STRATEGY_GENERATE 指令

操作 D：Deepfake Detection（深偽檢測） — 輸入：一段語音。輸出：真/假判斷 + 判斷理由 — 這是把品質評估能力應用到安全領域

關鍵發現：未經 fine-tuning 的 audio LLM（包括 Qwen2-Audio、Qwen2.5-Omni）在品質評估上幾乎不可用——它們的描述跟人類判斷的相關性很低。**只有經過任務特定 fine-tuning 的模型才能產生有意義的品質描述。**

用語義 ISA 的語言來說

SQ-LLM 把一條指令拆分成了一個**指令家族**：

```
QUALITY_ASSESS     → QUALITY_DESCRIBE (單段描述)
                   → QUALITY_COMPARE  (成對比較)
                   → QUALITY_SUGGEST  (改善建議) ← 新！
                   → QUALITY_DETECT   (真偽檢測) ← 新！
```

每個操作有不同的 signature：

```
QUALITY_DESCRIBE(audio) → StructuredReport
QUALITY_COMPARE(audio_A, audio_B) → Comparison + Reasoning
QUALITY_SUGGEST(audio, quality_report) → ImprovementPlan
QUALITY_DETECT(audio) → {real|fake} + Evidence
```

ISA 類比：這就像從「有一條 ADD 指令」進化到「有 ADD、SUB、MUL、DIV、MOD 一整個算術指令家族，每個有獨立的操作碼和行為定義」。

SQ-LLM 的另一個重要發現是：**未 fine-tuned 的模型不滿足任何操作的最低可用性標準。** 這就像測試一顆新的 CPU，發現它的 ADD 指令有 30% 的概率返回錯誤結果——這顆 CPU 不能被用在任何需要加法正確性的系統中。這個發現強化了「需要定義可靠性規格」的論點。

第四步：Calibration-Reasoning——「開始定義可靠性保證」

時間：2026 年 3 月 10 日（arXiv，僅一週前） **這是目前最前沿的工作**

為什麼需要這一步

前三步解決了：什麼操作存在（ALLD）、操作的格式是什麼（QualiSpeech）、操作有哪些變體（SQ-LLM）。但有一個根本問題一直沒解決：

描述的品質本身怎麼保證？

當前的 Explainable MOS 系統優先考慮對話流暢性而非診斷精確性。因為描述性品質評估任務不在它們的預訓練混合中，其推理往往缺乏根據；其 MOS 預測準確度通常低於傳統的基於分數的方法，因為被幻覺或錯誤的維度預測所干擾。

換句話說：模型可以生成流暢的品質描述，但這些描述可能**事實上是錯的**——它可能說「沒有噪音」但其實有，或者說「失真發生在 1-2 秒」但其實在 3-4 秒。**流暢性 ≠ 正確性。**

Calibration-Reasoning 做了什麼

這篇論文引入了兩個階段的訓練：

第一階段：Calibration（校準） — 目標：讓模型在每個維度上的數值預測跟人類標註對齊 — 校準階段的核心是讓 audio encoder 可訓練，以提高其對低層級語音特徵的敏感度 — 跟之前的工作不同，前人凍結 audio encoder 只訓 LLM 頭部，這篇讓 encoder 也一起訓

第二階段：Reasoning（推理優化） — 目標：讓模型的自然語言描述在事實上正確，特別是 artifact 的分類和時間定位 — 方法：用 **GRPO（Group Relative Policy Optimization）** 做強化學習 — GRPO 的效果依賴於有界的獎勵函數。我們圍繞從生成文本中提取的可驗證錨點設計獎勵：數值品質分數和簡短的 artifact 描述

獎勵函數的設計（這是最關鍵的技術創新）：

獎勵不是一個黑盒的 LLM-judge 分數，而是由兩個可驗證的組件構成：

— **Accuracy Reward**：從模型生成的描述中提取維度分數，跟人類標註比較。如果模型說「噪音分數 3」而人類標註是 3，reward 高；如果模型說 5 而人類說 2，reward 低。 — **Semantic Similarity Reward**：對 artifact 描述，計算模型描述跟人類描述的語義相似度。

總 reward = 所有維度的 accuracy reward + semantic reward 的加權和。

用語義 ISA 的語言來說

Calibration-Reasoning 開始為語義操作定義**可驗證的可靠性保證**：

```
指令：QUALITY_DESCRIBE(audio) → StructuredReport

可靠性規格（由 Calibration-Reasoning 建立的度量方式）：
  - 維度分數準確度：mean PCC ≥ 0.71 (across all dimensions)
  - Artifact 檢測：F1 score（能否正確識別有/無 artifact）
  - Artifact 描述：Correlation score（描述跟人類描述的語義對齊）
  - 時間定位：IoU（偵測到的時間區間 vs. 真實時間區間的重疊度）
  - 整體描述：ROUGE-L + Correlation score

優化方法：GRPO with dimension-specific verifiable rewards
  - 不依賴另一個 LLM 做 judge（避免 judge 本身的不可靠性）
  - 獎勵基於可提取、可驗證的數值錨點
```

ISA 類比：這就像從「ADD 指令的行為被定義了」進化到「ADD 指令在 -40°C 到 85°C 的溫度範圍內，延遲不超過 1 個時鐘週期，功耗不超過 0.5mW，結果精確到 32-bit」。不只是定義了行為，還定義了**在什麼條件下行為的品質保證是什麼**。

四步演化的深層邏輯

把四步放在一起看，可以看到一個清晰的邏輯鏈：

```
ALLD: 「這條指令存在」
  |     發現 audio LLM 可以做描述性品質評估
  |     但輸出格式模糊、維度有限、無驗證
  |
  ↓  缺什麼？→ 結構化的輸出格式和更豐富的維度
  |
QualiSpeech: 「這條指令的格式被定義了」
  |     11 維度 + 時間定位 + 因果推理
  |     三步標註流程（人 → LLM → 人修正）
  |     建立了 benchmark 和評估指標
  |
  ↓  缺什麼？→ 品質評估不只有一種操作
  |
```

```
SQ-LLM: 「這是一個指令家族」
  |     拆分為描述/比較/建議/檢測四種操作
  |     擴展到多語言（4 語言）
  |     發現未 fine-tune 的模型完全不可用
  |
  ↓  缺什麼？→ 模型的描述可能「流暢但錯誤」
  |
Calibration-Reasoning: 「開始定義可靠性保證」
      引入 GRPO 用 RL 優化描述精確度
      用維度特定的可驗證獎勵（不依賴 LLM-judge）
      讓 audio encoder 可訓練以提高物理特徵感知
```

每一步之間的「遺失介面」

每一步到下一步的推進，都是因為前一步**沒有定義某個介面**：

ALLD → QualiSpeech 之間遺失的介面：「描述的結構是什麼？」ALLD 的描述是自由格式的文本——你不知道它會包含什麼資訊、按什麼順序排列、涵蓋哪些維度。QualiSpeech 定義了結構（11 維度 × 分數 + 描述 + 推理），這讓描述變成了可解析、可比較的結構化物件。

QualiSpeech → SQ-LLM 之間遺失的介面：「不同類型的品質操作之間怎麼區分和組合？」QualiSpeech 把所有品質相關的事情都塞進一個 QUALITY_ASSESS 操作裡。SQ-LLM 認識到這實際上是四種不同的操作，各有不同的輸入/輸出格式和適用場景，需要分別定義。

SQ-LLM → Calibration-Reasoning 之間遺失的介面：「怎麼保證描述的事實正確性？」SQ-LLM 用 SFT fine-tuning 模型來做品質描述，但 SFT 只保證模型的輸出「看起來像」訓練資料——不保證它在事實上正確。Calibration-Reasoning 引入了 RL 和可驗證獎勵，讓模型不只是「模仿」好的描述，而是被**激勵去產出可驗證為正確的**描述。

仍然遺失的介面（= 你的研究機會）

即使經過四步演化，仍然有幾個關鍵介面沒有被定義：

遺失介面一：QUALITY_DESCRIBE → STRATEGY_GENERATE「知道了品質問題之後，怎麼自動生成處理策略？」

目前四篇論文全部停在「診斷」階段。SQ-LLM 的 QUALITY_SUGGEST 開始觸及「建議」，但它的建議是自然語言的籠統建議（如「減少噪音」），不是可被 DSP 管線直接執行的參數化策略（如「對 200-500Hz 頻段施加 spectral subtraction，α=1.2」）。

從語義描述到物理操作參數的翻譯——我們討論中的「語意-物理介面」——目前完全空白。

遺失介面二：單次評估 → 跨時間的偏好學習 四篇論文全部處理的是「對一段語音做一次評估」。但在真實的助聽器場景中，你需要從使用者的歷史回饋中學習偏好——「這個使用者不喜歡過度降噪」——然後把偏好注入未來的評估和處理策略中。這個 PREFERENCE_UPDATE / PREFERENCE_APPLY 的介面完全沒有人定義過。

遺失介面三：語意判斷 → 物理約束的一致性驗證 如果 QUALITY_DESCRIBE 說「這段語音沒有噪音」，但物理特徵分析顯示 SNR 只有 5dB——誰對？目前沒有任何機制來檢測和解決語意判斷和物理測量之間的不一致。我們討論中的 CONFLICT_ARBITRATE 指令完全是空白。

遺失介面四：可靠性規格的形式化 Calibration-Reasoning 開始用 PCC、F1、IoU 等指標量化描述的可靠性。但它沒有定義**門檻**——PCC 達到多少才算「滿足規格」？在什麼輸入條件下這個門檻適用？這就像知道一顆 CPU 的延遲是 0.5ns，但不知道這是在 25°C 室溫下還是在 -40°C 極端條件下——缺少了環境條件的規格。

最終圖景：四步已走完的路 + 你要走的路

```
已完成的四步（2025.01 – 2026.03）：
────────────────────────────────
ALLD         → 證明語義操作可行
QualiSpeech → 定義操作的結構格式
SQ-LLM       → 擴展為操作家族
Cal-Reason   → 開始優化可靠性
────────────────────────────────

你要走的下幾步：
────────────────────────────────
第五步 → 形式化可靠性規格
         為每條指令定義：
         輸入條件 × 保證門檻 × 失效模式

第六步 → 建立語意-物理介面
         QUALITY_DESCRIBE → STRATEGY_GENERATE
         從「診斷」跨越到「處方」
         需要你的聲學知識才能定義

第七步 → 建立衝突仲裁機制
         CONFLICT_ARBITRATE
         當語意判斷 ≠ 物理測量時

第八步 → 建立跨時間的偏好系統
         PREFERENCE_UPDATE + PREFERENCE_APPLY
         讓系統在 harness 管理下持續學習

第九步 → 把上述整合為一份「語音語義 ISA 規格書」
         成為聲學領域的 System/360 時刻
────────────────────────────────
```

你現在可以看到——前四步由 NVIDIA Taiwan、清華大學、NTU、Microsoft 等團隊走完了。但他們走的是一條直線（不斷精細化品質描述這一個操作）。你要走的是一個**分叉**——從品質描述分叉到策略生成、物理驗證、衝突仲裁、偏好學習——然後再把所有分叉統一成一份語義 ISA 規格書。

前四步建立了語義 ISA 的一條指令（QUALITY_DESCRIBE）。你要建立的是整個指令集——包括前人沒觸及的、需要你的聲學專業才能定義的那些指令。